



Les fondamentaux de la statistique appliquée



Bienvenue

Bilal AL TAKI

Le 11/05/2026 & 12/05/2026





**Faisons
Connaissance**

Participant	Métier
Vivien Raymond	Ingénieur R&D (Veolia)
Julie Coutton	Chargée Etude&Dev (Activités sociales de l'énergie)
Mélanie Farago	Météorologiste (Ge Vernova)



Avant de commencer

Durée de la formation : 2 jours

Organisation :

- Horaires : 9h à 17h00
- Pauses : 15 mins en matinée et après-midi (vers 10h30 et 15h15)
- Déjeuner : 12h30 à 13h30

Vos attentes

Julie :

- Gagner en efficacité dans l'analyse de mes données
- Réaliser des études pertinentes et fiables
- Interpréter correctement les résultats afin de formuler des propositions concrètes d'évolution
- Me familiariser avec les notions fondamentales de statistiques et renforcer mes compétences en analyse de données.

Vivien :

- Exposer/expliciter des résultats de traitement de données avec de solides fondements mathématiques.
- Expliquer des phénomènes observés dans les données en les validant à l'aide de "modèles" mathématiques.
- Exprimer des différences significatives entre mode opératoire, méthodes de mesures.
- Test/validation de corrélation entre des paramètres mesurés.

Mélanie :

- Mieux comprendre les différences entre les lois de distribution couramment utilisées (Weibull, normale/gaussienne)
- Approfondir le sens et l'apport des différents tests et indicateurs statistiques : Savoir ce que mesure chaque test et dans quel contexte il est le plus pertinent
- Comprendre les différences entre MAE, RMSE, R^2 et ce que chacun apporte comme information
- Identifier les avantages et limites de chaque métrique pour comparer un modèle à des données mesurées
- Mieux interpréter les erreurs entre deux séries temporelles (modèle vs mesures)

Objectifs de la formation

Cette formation vise à :

- ✓ Connaître les fondamentaux de l'analyse statistique appliquée
- ✓ Maîtriser l'utilisation des formules et tests statistiques fondamentaux
- ✓ Savoir concevoir un rapport d'analyse basé sur les faits
- ✓ Comprendre comment mesurer la confiance dans ses résultats
- ✓ Être en mesure de prévoir les comportements à venir
- ✓ Savoir vérifier l'adéquation à un modèle
- ✓ Transformer les résultats en décisions concrètes (réglages, choix de procédé, plan d'action)

Notions clés abordées dans la formation

- 1. Statistiques descriptives & exploration** : Moyenne, médiane, variance, écart-type, quartiles, IQR, coefficient de variation. Histogrammes, boxplots, analyse visuelle.
- 2. Incertitude & lois de probabilité (cadre de décision)** : Variabilité d'échantillonnage, Lois de référence utiles (loi normale, loi de Student, loi du χ^2). Quantiles, valeur critique, seuil de risque
- 3. Intervalles de confiance IC sur une moyenne** : Interprétation correcte d'un IC Lien entre IC et tests statistiques
- 4. Régression linéaire** : expliquer et prévoir, Corrélation vs régression, Modèle linéaire simple, Interprétation des paramètres (pente, R^2). Métriques d'erreur : MAE, RMSE. Diagnostic via les résidus
- 5. Tests statistiques** : décider avec un risque maîtrisé. Logique des tests : H_0 / H_1 , p-value. Lien fondamental : test $\leftrightarrow$ loi de probabilité. Tests de comparaison : Student (indépendant, apparié) ANOVA (1 facteur, multi-facteurs) Tests sur distributions : normalité (D'Agostino) adéquation (KS) Test du χ^2 (variables catégorielles)
- 6. Mise en pratique (Excel & Python)** : Ateliers guidés, Cas concrets métier, Interprétation et restitution des résultats

Plan de formation - Jour 1 — Comprendre et décrire les données

Statistiques descriptives & exploration

- Indicateurs clés : moyenne, médiane, dispersion, quartiles, CV
- Visualisation : histogrammes, boxplots, Analyse visuelle.

Atelier 1 – Excel & Python

- Description et visualisation des données
- Lecture critique avant toute modélisation

Incertitude & lois de probabilité

- Pourquoi parler de lois (Normale, Student, χ^2) : rôle et interprétation
- Quantiles, seuil de risque (α)

Intervalles de confiance

- IC d'une moyenne (loi de Student)
- Démonstration Excel pas à pas

Plan de formation - Jour 2— Modéliser, tester et décider

Régression linéaire

- Corrélation vs régression
- Modèle linéaire, estimation par OLS, MAE, RMSE, R^2 : évaluation du modèle
- Diagnostic par les résidus

Tests statistiques


- Logique des tests : H_0/H_1 , p-value
- Lien fondamental : test $\leftrightarrow$ loi de probabilité
- Student, ANOVA, χ^2 , D'Agostino, KS

Atelier 2 – Excel & Python

- Choisir le test adapté
- Interpréter les résultats
- Formuler une décision métier

Conclusion & validation

- Synthèse du raisonnement statistique
- QCM (questions techniques & métier)



Introduction



Commençons par ce que vous connaissez déjà :

- Pourquoi la statistique?
 - A quoi sert-elle ?
 - Les deux visages de statistiques (descriptive et inférentielle)
 - Notions de base (vocabulaire commun)
- 

Origine de statistique

Origine: L'origine du mot "statistique" remonte au latin classique status (état) qui, par une série d'évolutions successives, aboutit au terme français statistique, attesté pour la première fois en 1771.

Status → stato → statista → statistica → statisticus → Statistique

(1633)

(1672)

(1771)

C'est vers la même époque que statistik apparaît en allemand, alors que les anglophones utilisent l'expression political arithmetic jusqu'en 1798, date à laquelle le mot statistics fait son entrée dans cette langue.

On distingue actuellement les statistiques (au pluriel) de la statistique (au singulier).

- **Les statistiques** (au pluriel) Les statistiques désignent des ensembles de données relatives à des groupes d'individus ou d'objets. Comme les statistiques du chômage, de la criminalité, du commerce extérieur, etc.
- **La statistique** (au singulier) désigne l'outil et l'ensemble des méthodes qui permettent la collecte, le traitement et l'interprétation de ces données.

But de statistique

Les données d'atelier présentent incertitude et variations pour plusieurs raisons :

- ▶ **Processus non parfaitement prévisibles** (variabilité matière première, micro-conditions de cave, influence de l'opérateur).
- ▶ **Mesures imparfaites** (calibrage des capteurs, résolution limitée, dérive des instruments).
- ▶ **Échantillonnage partiel** (on n'observe qu'une partie de la production).
- ▶ **Effets temporels** (dérive dans le temps, saisonnalité, différence entre lots).

⇒ Données issues de phénomènes aléatoires

⇒ Intervention du **hasard** et des **probabilités**

But de la statistique : Passer du désordre à la décision mesurée en :

- ▶ **Quantifiant l'incertitude** (moyennes, variances, intervalles de confiance).
- ▶ **Séparant le signal du bruit** (tests, modèles, contrôle des facteurs).
- ▶ **Prédisant et surveillant les performances** (capabilité, seuils d'alerte).
- ▶ **Optimisant les réglages du procédé** (plans d'expériences, choix recette/fournisseur).

Deux visages complémentaires de la statistique

1^{er} Visage : Statistique descriptive — *Voir et résumer ce qui se passe*

- **But** : synthétiser l'information pour rendre les données lisibles et comparables.
- **Outils** :
 - ▶ **Représentations graphiques** : histogrammes, courbes d'évolution, boîtes à moustaches, Pareto des défauts, nuages de points.
 - ▶ **Indicateurs simples de position et de dispersion** (ex. médiane, quartiles, étendue) et relation visuelle entre variables.
 - ▶ **Repérage de tendances** et d'irrégularités (saisonnalité, dérives) par des graphiques ou une ligne de tendance.
- **Exemples métier** :
 - ▶ **Automatisation / Data** : Temps de traitement + taux d'erreur d'un pipeline par jour (courbe + boxplot) → détecter une dérive après mise à jour..
 - ▶ **Instrumentation qualité de l'eau** : Turbidité / pH / conductivité par site ou par campagne (histogramme + quartiles) → visualiser variabilité et anomalies.
 - ▶ **Éolien offshore / charges & vent** : Distribution de vitesse du vent / TI / rafales (histogramme + quantiles) → caractériser le régime et les extrêmes.
 - ▶ **Ce que ça apporte** : dégage les caractéristiques essentielles du phénomène et suggère des hypothèses pour aller plus loin (tests, plans d'expériences).

Les probabilités jouent ici un rôle mineur : l'enjeu est surtout la lecture et la synthèse

Deux visages complémentaires de la statistique

2^{ème} visage : Statistique inférentielle — Généraliser, prévoir et décider

- **But** : conclure au-delà des données observées (échantillons), prévoir et prendre des décisions avec un cadre de risque maîtrisé.
- **Outils (ce qu'on va utiliser dans la formation) :**
 - Estimation & Intervalles de confiance (IC) : quantifier l'incertitude sur une moyenne, une proportion, une différence.
 - Tests d'hypothèses : décider si une différence/association est "réelle" au-delà du bruit.
 - Modèles simples de prédiction/explication : régression linéaire + diagnostic (adéquation via résidus)..
- **Exemples métiers (vos profils) :**
 - **Automatisation / data** : La nouvelle version du pipeline a-t-elle augmenté le temps de traitement ? → Student/ANOVA + IC
 - **Instrumentation qualité de l'eau** : Deux méthodes de mesure donnent-elles des valeurs moyennes différentes ? → Student + IC ; Le taux de dépassement d'un seuil dépend-il du site ? → χ^2
 - **Offshore wind / loads** : Les charges (DEL/moments) diffèrent-elles entre états de mer / secteurs de vent ? → ANOVA + IC ; Une variable météo explique-t-elle une charge ? → régression
- **Ce que ça requiert :**
 - définir des modèles probabilistes (comment on suppose que les données se comportent) et gérer les risques d'erreurs (fausse alarme vs non-détection).

A thick, light green wavy line that starts on the left side of the slide, curves downwards and to the right, then curves upwards and to the right, and finally curves downwards and to the right again, ending near the bottom right corner.

Quelques notions de base utilisée en statistiques

Ces notions vous sont-elles familières ?

Ces notions vous sont-elles familières ?

- Population
- Échantillon
- Variable
- Observation
- Quantitative / qualitative
- ...

.

Population

Définition : ensemble d'objets sur lequel on veut conclure.

Exemples :

- Toutes les meules produites semaine 4.
- Tous les lots de la ligne A.
- Toutes les cuves de lait de janvier.

Mini-exercice : “Quelle est la population si l'on veut évaluer la conformité d'Extrait sec pour le Camembert en période 2 ?”

Note : les résultats de l'échantillon sont utilisés pour représenter la population.

Individu (unité statistique)

Définition : un élément appartenant à la population.

Exemples :

- Une meule, un lot, une cuve, une journée de production.

Mini-exercice : “Dans un contrôle par lot, l’individu est-il la meule ou le lot ?

Note : bien fixer l’unité avant tout calcul.

Variable statistique

Définition : Une variable statistique est une caractéristique observée ou mesurée sur chaque individu.

Deux types de variables :

- **Variables qualitatives :**
 - Nominales : pas d'ordre logique
 - Ordinales : Ordre possible
- **Variables quantitatives :**
 - Discrètes : nombre fini/dénombrable
 - Continues : intervalle réel

Mini-exercice : classer ces variables sous les bonnes catégories :

- Extrait sec
- MG/Litre
- PH
- Nb de fromages produits/jour
- Nb de moules utilisés
- Nb de lots produits
- Récupération MG%
- Teneur en seul
- Conforme/non-Conforme

Donnée mesurée	Type de variable	Continue / Discrète	Justification
Extrait sec (%)	Quantitative	✓ Continue	Mesuré en %, peut prendre une infinité de valeurs (ex. 52,3 % ; 52,37 %)
MG / litre (g/L)	Quantitative	✓ Continue	Mesure de masse par volume, valeurs réelles possibles
pH	Quantitative	✓ Continue	Mesure logarithmique pouvant prendre une infinité de valeurs
Teneur en sel (%)	Quantitative	✓ Continue	Résultat d'une mesure chimique continue
Récupération de MG (%)	Quantitative	✓ Continue	Proportion mesurée avec précision décimale
Température (°C)	Quantitative	✓ Continue	Variable issue d'une mesure physique
Masse du fromage (kg)	Quantitative	✓ Continue	Peut prendre des valeurs réelles
Durée d'affinage (jours)	Quantitative	✓ Continue	Mesurable avec précision (jours, heures)
Nombre de fromages produits / jour	Quantitative	✓ Discrète	Comptage → valeurs entières
Nombre de moules utilisés	Quantitative	✓ Discrète	Résultat d'un dénombrement
Nombre de lots produits	Quantitative	✓ Discrète	Valeurs entières uniquement

Observation

Définition : Une observation est la valeur d'une variable mesurée sur un individu.

- 👉 Variable = ce qu'on mesure
- 👉 Observation = le résultat de cette mesure

Exemples :

- **% H₂O = 52,1 % pour la meule #1845.**
- **pH = 6,47 sur le lot L032.**

Individu	Variable	Observation
Meule#1845	%H ₂ O	52,1%
Lot L032	pH	6,47

Effectifs (Fréquences absolues)

Définition : L'effectif est le nombre d'individus observés dans un ensemble de données.

- Il correspond au nombre d'observations réalisées
- On parle aussi de taille de l'échantillon

Notations usuelles

- n : effectif total observé
- n_i : effectif d'une catégorie ou d'un groupe

Exemple – Fabrication de fromage

- 50 meules prélevées sur une journée de production → Effectif total : $n = 50$

Par type de produit :

- Tomme : 30 meules → $n_1 = 30$
- Raclette : 20 meules → $n_2 = 20$

Echantillon

Définition : sous-ensemble de la population effectivement observée, selon un plan d'échantillonnage.

- Plans courants : Aléatoire simple (tirage au hasard).
- Systématique (1 sur n).
- Stratifié (par produit, période, cuve).

Exemples :

- 30 meules prélevées "1 sur 50" sur la ligne.
- 10 meules par lot (stratifié).

Mini-exercice : proposer un plan pour comparer l'Extrait sec entre périodes 1 vs 2

Construction d'un échantillon

Problème : Mesurer toute la population ou travailler sur un échantillon ?

Ex : Doit-on contrôler tous les lots ou sélectionner un échantillon ?

- **Idéal (théorique) :** Mesurer l'ensemble pour obtenir des résultats sans approximation.
- **Réalité (terrain) :** Les contraintes de temps, de coûts et d'accès rendent le recensement impraticable.
- **Décision :** Construire un échantillon représentatif de la population pour sonder efficacement.

A retenir

- On **définit la population**.
- On **choisit l'individu (unité)**.
- On **sélectionne les variables** (type & échelle).
- On **observe un échantillon** représentatif (plan d'échantillonnage).
- **Ensuite** : descriptifs, IC, tests, modèles → **décision procédée**.


Population

Individus

Variables

Observations

Echantillons



Statistiques descriptives



Plan :

- Représentation graphique
 - Mesures de tendance centrale
 - Mesures de dispersion
 - Liaison entre variable
- 

Introduction à la statistique descriptive

La **statistique descriptive** vise à :

- **Recueillir** des données pertinentes (objectif, périmètre, qualité des mesures)
- **Organiser** ces données de manière structurée (format, variables, unités, cohérence)
- **Résumer** l'information (indicateurs + graphiques) pour rendre les données lisibles
- **Interpréter** les résultats afin d'éclairer la prise de décision (constats factuels)

Application :

- Suivi d'un **indicateur clé** dans le temps (qualité, performance, délai, coût)
- Analyse du **taux d'anomalies / non-conformités / incidents**
- **Pareto** des défauts / causes / motifs d'erreur (priorisation)
- Analyse de la **variabilité** d'une mesure (poids, dimension, délai, consommation, etc.)
- Comparaison entre **sites / équipes / périodes / méthodes** (boxplots, distributions)

La statistique descriptive permet de comprendre les données avant toute décision.

Où la statistique descriptive crée de la valeur (avant les tests)

Bloc 1 — Qualité & conformité

- Décrire la variabilité d'un indicateur clé (mesure, performance, délai, coût)
- Comparer sites / lots / périodes / méthodes (stabilité, dispersion, outliers)

Bloc 2 — Process & fiabilité

- Prioriser les problèmes : Pareto des défauts / incidents / causes
- Surveiller l'évolution : dérives, ruptures, saisonnalité (courbes temporelles)

Bloc 3 — Utilisateurs & impact

- Qualifier les retours (tickets, réclamations, incidents) : fréquence + gravité
- Comparer l'expérience selon contexte (site, version, protocole, canal)

Décrire d'abord : comprendre le "quoi". Tester ensuite : décider sur le "pourquoi" avec un risque maîtrisé (IC, tests, régression).

Remarque importante

Avant toute analyse : 2 questions à se poser

➤ Quel type de donnée ?

- Quantitative (mesure) : continue / discrète
- Qualitative (catégorie) : nominale / ordinale / binaire

➤ Quel objectif d'analyse ?

- Décrire (niveau / dispersion) → moyenne, médiane, IQR, écart-type, CV
- Comparer (groupes/périodes) → Student / ANOVA + IC
- Tester une dépendance (catégories) → χ^2
- Expliquer / prédire ($X \rightarrow Y$) → régression + diagnostic (résidus)

Représentations graphiques

La **représentation graphique** est essentielle en statistique descriptive :

- ▶ Visualisation rapide des caractéristiques d'un jeu de données ;
- ▶ Compréhension de la distribution (centrage, dispersion, asymétrie) ;
- ▶ Détection d'anomalies ou de valeurs extrêmes ;
- ▶ Communication efficace avec un public non spécialiste.

Deux outils fréquents :

- ▶ Histogramme
- ▶ Boite à moustaches (Boxplot)

Histogramme

Définition : Représente une **variable quantitative continue**. Données regroupées en **classes** (amplitude égale ou non).

Chaque barre :


- Base : intervalle de classe,
- Hauteur : effectif ou densité

Attention : en cas de classes inégales, on ajuste la hauteur pour que l'aire représente la fréquence.

Histogramme – Exemple

Répartition des salaires (k€)

Classe de salaire (k€)	Effectif
[20,30[	12
[30,40[	23
[40,50[	35
[50,60[	15
[60,70[	10



La majorité des employés gagnent entre 30k et 50k

Histogramme – Applications et remarques

Applications typiques

- ▶ Mesures continues (capteurs/process) : pH, conductivité, température, vibration, vitesse du vent, charges...
- ▶ KPI opérationnels : temps de cycle, latence, énergie, rendement, durée d'arrêt
- ▶ Qualité & conformité : distribution par lot/site/méthode, repérage de dépassements de seuil
- ▶ Avant/Après changement : comparaison de formes (décalage, dispersion, apparition de second mode)

Ce qu'un histogramme permet de diagnostiquer

Les données sont regroupées en classes contiguës (barres accolées)

- ▶ Niveau : où se situe la masse des valeurs (centre)
- ▶ Dispersion : procédé stable ou variable Asymétrie : distribution non normale / effets de seuil
- ▶ Multimodalité : mélange de régimes (2 populations, 2 modes opératoires)
- ▶ Queues/outliers : événements rares mais critiques (pannes, extrêmes)

L'histogramme permet de visualiser rapidement la dispersion, la variabilité et les valeurs atypiques d'un procédé de fabrication.

Boîte à moustaches (Boxplot)

Définition : représentation synthétique de la distribution d'une variable quantitative (niveau, dispersion, asymétrie, valeurs atypiques), utile pour comparer des groupes (sites, périodes, méthodes, versions...).


Composants :

- **Médiane (Q2)** : 50 % des données en dessous / au-dessus
- **Quartiles** :
 - Q1 : 25 % des données en dessous
 - Q3 : 75 % des données en dessous
- **IQR (écart interquartile)** : $IQR = Q3 - Q1$ → dispersion "centrale" (robuste)
- **Moustaches** (règle standard) :
 - borne basse : $Q1 - 1,5 \times IQR$
 - borne haute : $Q3 + 1,5 \times IQR$
- **Valeurs atypiques (outliers)** : points au-delà des moustaches (à investiguer, pas à supprimer automatiquement)

Structure d'un boxplot

Structure :


- ▶ Boîte = $[Q_1; Q_3]$;
- ▶ Trait = Médiane;
- ▶ Moustaches aux extrémités standards ;
- ▶ Points = valeurs aberrantes.



Comparaison des salaires par département :

Lecture :

- ▶ Médiane plus élevée en **Marketing** ;
- ▶ **Dispersion plus forte** dans le département de marketing



Boxplot – Applications métiers

Boxplot - À quoi ça sert en pratique ?

- Comparer des distributions entre sites / périodes / lignes / équipes / versions → stabilité, dispersion, décalage du niveau “typique”.
- Comparer des méthodes / capteurs / protocoles → repérer un biais apparent et une différence de variabilité avant de tester (Student/ANOVA).
- Identifier des comportements atypiques (outliers) → incident, erreur de mesure, changement de régime, conditions extrêmes.
- Prioriser les investigations → où la variabilité est la plus forte ? quel groupe est le plus instable ?

Ce que montre un boxplot

- Médiane (Q2) : valeur centrale “typique” → compare le niveau entre groupes.
- Boîte (Q1–Q3) : dispersion centrale (IQR) → compare la stabilité (robuste aux extrêmes).
- Moustaches : étendue “standard” des données → donne une idée de la variabilité globale.
- Points isolés (outliers) : cas atypiques → à investiguer (erreur ? événement rare ? changement de conditions ?)

Mesure de tendance centrale

Les mesures de tendance centrale servent à **résumer une série de données par une valeur représentative**, autrement dit une **valeur qui donne une idée de "ce qui est normal" ou "typique"**.

Pourquoi en a-t-on besoin ?

Quand on a beaucoup de mesures, on ne peut pas tout regarder une par une. On cherche donc un point de repère pour comprendre rapidement le comportement global des données.

Principales mesures

➤ Moyenne

→ valeur globale (somme des valeurs / nombre de valeurs)

→ sensible aux valeurs extrêmes

➤ Médiane

→ valeur du milieu (50 % des données au-dessus, 50 % en dessous)

→ plus robuste en présence de valeurs aberrantes

➤ Mode

→ valeur la plus fréquente

→ reflète ce qui arrive le plus souvent

À retenir

👉 Une même série de données peut avoir plusieurs "centres"

👉 Le choix de la mesure dépend du contexte et de l'objectif

Moyenne arithmétique

Définition: La moyenne arithmétique mesure la valeur centrale d'un ensemble où chaque observation a la même importance.

$$\bar{x} = \frac{1}{n} \sum_{i=0}^n x_i$$

- ▶ x_i : i e observation
- ▶ n : nombre total d'observations

Quand l'utiliser ?

- ▶ Échantillons homogènes : même poids/importance pour chaque mesure (même lot, même protocole).
- ▶ Contrôles qualité où l'on veut la tendance centrale de mesures équivalentes.

À ne pas confondre :

- ▶ Si les observations n'ont pas la même importance (volumes, masses ou rendements différents), utiliser la moyenne pondérée (poids w_i) :

Moyenne pondérée

Définition : La moyenne pondérée tient compte de l'importance relative de chaque observation (toutes les valeurs ne "pèsent" pas autant).

Formule :

$$\bar{x} = \frac{\sum_{i=0}^N w_i x_i}{\sum_{i=0}^N w_i}$$

où x_i = valeur (teneur, coût, etc.) et w_i = poids (volume, masse, kg produits, etc.)

Quand l'utiliser ?

- Lorsque les observations n'ont pas la même contribution au résultat global
- Lorsque l'on agrège des résultats provenant de groupes de tailles/poids différents

Points clés :

- Choisir un poids cohérent avec la question (ce qui représente réellement "combien ça compte")
- Vérifier systématiquement les unités et la cohérence des dénominateurs
- Ne pas confondre : moyenne de ratios vs ratio global (ce n'est pas toujours équivalent)

Exemple1 - Standardiser la matière grasse (mélange)

Données :

- Lot A : 8 000 L à 3,90 % MG
- Lot B : 2 000 L à 0,05 % MG (écrémé)

Calcul (moyenne pondérée par le volume) :

$$\begin{aligned}\text{MG_mélange} &= [(3,90 \times 8\,000) + (0,05 \times 2\,000)] / (8\,000 + 2\,000) \\ &= (31\,200 + 100) / 10\,000 = 3,13 \%\end{aligned}$$

Conclusion : la MG finale du mélange est $\approx 3,13 \%$ ($\neq$ moyenne simple).

Moyenne : avantages et limites

Avantages :

- Facile à calculer
- Utilise toutes les valeurs

Limites :

- Sensible aux valeurs extrêmes
- Peut ne pas représenter le centre en cas de données asymétriques

Médiane

Définition : Valeur centrale d'une série ordonnée.

- Si n impair : médiane = valeur du milieu
- Si n pair : médiane = moyenne des deux valeurs centrales

Exemples :

- Série : 12, 14, 17, 18, 22 $\Rightarrow$ médiane = ?
- Série : 10, 12, 15, 18, 20, 21 $\Rightarrow$ médiane = ?

Quand l'utiliser ?

- Mesures avec valeurs aberrantes possibles (p. ex. meule sur-hydratée, défaut de pesée).
- La médiane est robuste : elle n'est pas tirée par les extrêmes.

Mode

Définition : Le mode est la valeur la plus fréquente dans un ensemble de données. S'applique aux variables catégorielles (types de défauts) et aux quantitatives discrètes (calibres, diamètres).

Quand l'utiliser ?

- Identifier le calibre le plus courant, le type de défaut dominant, la classe d'humidité la plus fréquente.
- Utile pour la logistique (emballages, moules, formats) et le pilotage qualité.

Exemple — diamètre des meules (cm)

- Données (cm) : 32 ; 32 ; 31 ; 32 ; 33 ; 32 ; 31 ; 33 ; 32 ; 32
- Comptages : 31 cm (2), 32 cm (6), 33 cm (2)
- **Mode = 32 cm (diamètre le plus fréquent)**

Interprétation

- Le format dominant est 32 cm → utile pour dimensionner la production (moules, cercles, emballages).
- Attention : variables continues (p. ex. humidité %) nécessitent un choix de classes ; un mode peut être multiple (bi- ou multimodal).

Mode : applications et limites

Applications

- Type de défaut d'emballage le plus fréquent
- Format de fromage le plus produit ou le plus vendu
- Cause dominante de non-conformité
- Classe de pH la plus observée

Avantages

- Très facile à interpréter
- Particulièrement adaptée aux variables qualitatives (ex. type de défaut, conformité, catégorie produit)
- Donne rapidement une tendance dominante

Limites

- Peu représentatif si les valeurs sont très dispersées
- Peut être multiple ou ambigu (plusieurs modes)
- Ne décrit ni la variabilité, ni la dispersion

Le mode indique ce qui est le plus courant, pas ce qui est typique au sens statistique

Résumé comparatif des mesures

Mesure	Avantages	Limites
Moyenne	Utilise toutes les données; simple à calculer	Très sensible aux valeurs extrêmes
Médiane	Robuste aux extrêmes; représentative en cas d'asymétrie	Ignore les données en dehors du centre
Mode	Facile pour les données qualitatives; concret	Peu utile si multimodale ou dispersion forte

Mesure de dispersion – quantifier la variabilité

- Les mesures de dispersion décrivent à quel point les données varient autour d'une valeur typique (hétérogénéité / stabilité).
- Deux séries peuvent avoir la même tendance centrale (moyenne ou médiane), mais une variabilité très différente → conséquences directes sur le risque, la qualité et la fiabilité.
- Elles complètent les mesures de tendance centrale : niveau + variabilité = lecture correcte d'un phénomène.

Etendue

Définition : L'étendue mesure l'amplitude totale des observations :

$$\text{Étendue} = x_{\max} - x_{\min}$$

Cas d'usage (quand c'est utile) :

- Contrôle express : repérage rapide d'un écart important dans un lot / une période / un échantillon
- Signal d'alerte : suspicion d'anomalie ou de conditions non maîtrisées

Limites (à annoncer clairement) :

- Très sensible aux valeurs extrêmes (un seul point peut tout changer)
- Ne décrit pas la dispersion "interne" (comment les données sont réparties entre min et max)

À retenir :

- Bon indicateur d'alerte instantané
- À compléter par un indicateur plus robuste (IQR, écart-type) pour conclure sur la stabilité

Variance

Définition : Pour un échantillon de taille n :

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

x_i : observations

$\bar{x}$: moyenne de l'échantillon

$n - 1$: correction "échantillon" (estimation non biaisée de la variance de la population)

Cas d'usage (pourquoi on la calcule) :

- Comparer la stabilité de plusieurs périodes / procédés / méthodes (à niveau comparable).
- Servir de base à l'écart-type et à des analyses de variabilité (qualité, capacité, suivi process).

À retenir :

- Plus s^2 est faible → plus le phénomène est stable (moins variable).
- Utiliser $n-1$ pour un échantillon, et n si l'on dispose de la population complète.

Ecart type & Coefficient de variation CV

Définition : L'écart-type est la racine carrée de la variance (échantillon) :

$$s = \sqrt{s^2}$$

Il mesure la dispersion **dans la même unité que la variable** (plus interprétable que la variance).

Coefficient de variation

$$CV = \frac{s}{x}$$

Mesure la variabilité relative (utile pour comparer des séries de niveaux différents).

Interprétation (en pratique) :

- s petit → données plus regroupées → phénomène/processus plus stable
- CV petit → variabilité faible par rapport au niveau moyen
- CV permet de comparer des variables/contextes à échelles différentes (à condition que $x \neq 0$)

Cas d'usage :

- Indicateur opérationnel pour piloter la stabilité (mêmes unités que la mesure)
- Comparer la variabilité entre périodes / sites / méthodes / versions Alimenter des décisions de suivi : quand investiguer une hausse de variabilité ?

Limites / précautions :

- CV n'est pertinent que si la moyenne est strictement positive (et pas proche de 0)
- En présence d'outliers, compléter par des indicateurs robustes (médiane/IQR)

À retenir :

- Plus s est petit, plus le phénomène est répétable
- CV donne une lecture relative : "combien ça varie par rapport au niveau moyen"

CV : Applications et remarques

À quoi ça sert (applications)

- Comparer la régularité d'un indicateur entre périodes / sites / équipes / méthodes / versions
- Repérer où la variabilité relative est la plus forte (zone de risque → investigation prioritaire)
- Suivre la stabilité d'un système dans le temps (monitoring : dérive, changement de régime)
- Objectiver une discussion "stable vs instable" lorsque les niveaux moyens diffèrent

Comment interpréter

- CV faible → variabilité faible par rapport au niveau moyen (comportement régulier)
- CV élevé → variabilité importante par rapport au niveau moyen (risque opérationnel/qualité accru)
- Le CV permet de comparer des contextes où les moyennes ne sont pas identiques (lecture relative)

Conditions & limites

- Pertinent si la moyenne $\bar{x}$ est non nulle et pas proche de 0
- Comparer uniquement des grandeurs de même nature (même unité / même indicateur)
- Le CV ne décrit pas la forme de la distribution (asymétrie, multimodalité, outliers) → à compléter par histogramme / boxplot / quantiles si nécessaire

Résumé comparatif de dispersion

Mesure	Avantages	Limites
Etendue	Simple et rapide	Très sensible aux extrêmes
Variance	Tient compte de tous les écarts à la moyenne	Difficile à interpréter (unités au carré)
Ecart-type	Mesure intuitive ; unité cohérente	Sensible aux extrêmes
CV	Comparaison entre séries différentes	Nécessite moyenne non nulle

Analyse bidimensionnelle — relier deux variables quantitatives

Quand ?

Lorsque deux variables quantitatives sont mesurées sur les mêmes unités (mêmes individus/objets/instants).

Objectif : Détecter et décrire une relation éventuelle : sens ($\uparrow/\downarrow$) et intensité (faible/forte)— avant de conclure.

Applications (transverses) :

- Mesure $\leftrightarrow$ performance (paramètre process vs rendement/qualité)
- Conditions $\leftrightarrow$ comportement (environnement vs dérive/dispersion)
- Charge $\leftrightarrow$ réponse (entrée vs sortie, capteur vs indicateur, etc.)

Outils d'exploration (ce qu'ils disent) :

- **Covariance** : indique le sens de variation commune (même sens / sens opposé) (dépend des unités, donc peu comparable entre variables différentes)
- **Corrélation de Pearson** : mesure force + sens du lien linéaire, $r \in [-1, +1]$ (comparables car normalisée)

Remarque :

- Si un lien apparaît, on le modélise ensuite par une régression linéaire (et on vérifie l'adéquation via les résidus).

Covariance - Définition

La covariance mesure le sens de variation commune entre deux variables quantitatives mesurées sur les mêmes individus.

$$\text{Cov}(X, Y) = \frac{1}{(n-1)} \sum_{i=1}^n (x_i - \bar{x}) * (y_i - \bar{y})$$

avec

- x_i, y_i : valeurs observées sur l'individu i
- $\bar{x}, \bar{y}$: moyennes des variables X et Y
- n : nombre d'individus observés

NB: Division par $n-1$ cas échantillon

Covariance – Interprétation

Interprétation :

- $\text{Cov}(X, Y) > 0$: les variables évoluent dans le même sens
- $\text{Cov}(X, Y) < 0$: relation inverse
- $\text{Cov}(X, Y) \approx 0$: absence de relation linéaire

Exemple :

X : budget pub (k€), Y : chiffre d'affaires (k€)

Si X augmente $\Rightarrow Y$ augmente $\text{Cov}(X, Y) > 0$

Covariance - limites

- Non normalisée : dépend des unités
- Difficile à interpréter seule
- Peu utile pour comparer des séries différentes

Corrélation linéaire de Pearson

La **corrélation de Pearson** mesure la force et le sens de la relation linéaire entre deux variables quantitatives mesurées sur les mêmes individus.

$$r = \frac{Cov(X, Y)}{\sigma_X \times \sigma_Y}$$

σ_X, σ_Y : écarts-types des variables X et Y

$r \in [-1, 1]$: valeur normalisée


Corrélation – Interprétation

Valeur de r	Interprétation
$r > 0,8$	Corrélation forte et positive
$0,5 < r \leq 0,8$	Corrélation modérée et positive
$0,2 < r \leq 0,5$	Corrélation faible
$-0,2 \leq r \leq 0,2$	Corrélation quasi-nulle
$r < -0,2$	Corrélation négative

Applications métiers

- **Marketing** : budget pub vs ventes
- **Finance** : corrélation entre portefeuilles
- **Économie** : chômage vs consommation

Représentation graphique : nuage de points (*scatter plot*)



Corrélation Causalité

Un coefficient r élevé **n'implique pas** un lien de cause à effet.

— **Exemple absurde :**

- Consommation de chocolat ↑
- Nombre de prix Nobel ↑
- ⇒ Pas de lien de causalité. Facteurs communs possibles : niveau de vie, éducation...

Résumé – Covariance vs Corrélation

Mesure	Utilité	Limites
Covariance	Indique le sens de la relation entre deux variables	Non normalisée, dépend des unités
Corrélation	Mesure la force et le sens d'une relation linéaire (normalisée)	Ne détecte pas les relations non linéaires ; ne prouve pas une causalité



Je reste
disponible pour
toute question

Atelier

Activité

1h30 heures



Contexte

Une organisation industrielle instrumentée souhaite mieux maîtriser la performance et la fiabilité d'un système (process / maintenance) et comprendre l'évolution d'indicateurs clés dans le temps.

Données mises à disposition : Mesures réalisées sur plusieurs périodes (1 à 4), avec :

- Variables process : Temperature_C, Pression_bar, Charge_kNm
- Variables maintenance : Vibration_mm_s, Arret_min, Defaults_nb
- Variable performance/qualité (cible) : Indice_Qualité
- Variables de segmentation : Periode, Site, Mode_Operatoire

Objectif (première étape) : Utiliser les outils de statistique descriptive et bidimensionnelle (moyenne/médiane, dispersion, histogramme, boxplot, covariance, corrélation) pour produire un diagnostic factuel et préparer la suite : IC + tests + adéquation..

Phase 1 – compréhension des données (30 mins)

Objectif : Décrire la variable cible Indice_Qualité selon les périodes (1 à 4).

Travail demandé : Pour chaque période :

- Calculer moyenne, médiane, variance, écart-type, Q1/Q3 (IQR), min/max
- Comparer les périodes : niveau “typique” (moyenne vs médiane) stabilité (écart-type / IQR)
- présence d’écarts ou de valeurs atypiques

Outils autorisés

Fonctions Excel + filtres

Questions à se poser

- Quelle période a l’indice qualité le plus élevé ?
- Quelle période est la plus instable (dispersion la plus forte) ?
- Moyenne et médiane racontent-elles la même histoire (asymétrie/outliers) ?

Livrables attendus

- Un tableau récapitulatif des statistiques par période
- Une interprétation courte (3–5 lignes) : constats + hypothèse(s)

Phase 2 – Représentations graphiques (30 mins)

Objectif : Comparer visuellement les distributions autour de Indice_Qualite.

Travail demandé

Construire :

- Histogramme de Indice_Qualite (global)
- Histogramme de Arret_min (commenter la forme : asymétrie/outliers)
- Boxplot comparatif de Indice_Qualite par Periode (option : boxplot par Mode_Operatoire ou Site si temps)

Observer

- position centrale (médiane/moyenne)
- dispersion (IQR/étendue)
- valeurs atypiques (points isolés)
- changements de forme (asymétrie, multimodalité)

Questions à se poser

- Les distributions changent-elles entre périodes ?
- Est-ce un décalage de niveau, une instabilité, ou un mélange de régimes ?
- Les outliers sont-ils plausibles (événement rare) ou suspects (qualité de mesure) ?

Livrables attendus

- Graphiques réalisés + commentaire qualitatif (3–5 lignes)

Phase 3 : Corrélations et relation linéaire (30 min)

Objectif : Étudier la relation entre Indice_Qualite et des variables process/maintenance

Travail demandé

- Calculer covariance et corrélation de Pearson :
 - $\text{Vibration_mm_s} \leftrightarrow \text{Indice_Qualite}$
 - $\text{Charge_kNm} \leftrightarrow \text{Vibration_mm_s}$
- Interpréter : signe, intensité, cohérence métier, limites (corrélation $\neq$ causalité)
- Construire une matrice de corrélation (au moins 4 variables quantitatives)

Méthodes (Excel)


- =COVARIANCE.S(plage1;plage2) et =CORREL(plage1;plage2)
- Matrice : outil / formules selon votre pratique

Questions à se poser

- Quelles variables évoluent ensemble ?
- Le lien observé est-il cohérent métier (mécanisme plausible) ?
- Quelle hypothèse testable formuler pour la suite (IC/tests/régression) ?

Livrables attendus

- 1 corrélation commentée + 1 matrice de corrélation
- Conclusion (5 lignes) : constats $\rightarrow$ hypothèse(s) $\rightarrow$ prochaine étape



Les lois de probabilités



Plan du chapitre :

- Introduction : la notion d'aléa et d'incertitude
 - À quoi servent les lois de probabilités en pratique
 - Présentation des lois de probabilités les plus courantes
 - Rôle des lois de probabilités dans les tests statistiques
- 

De la description à la décision : pourquoi parler de lois ?

Les **statistiques descriptives** (moyenne, écart-type, médiane...) décrivent ce qu'on observe

Mais elles ne disent pas :

- si une différence est réelle ou due au hasard
- si un écart est significatif ou attendu

Pour décider, il faut :

- modéliser l'incertitude
- comparer ce qu'on observe à ce qu'on attendrait par hasard

C'est le rôle des lois de probabilité.

Cartographie des lois usuelles : Discrètes et Continues

Lois continues – Mesures physico-chimiques : Utilisées pour les mesures réelles issues des capteurs et analyses laboratoire.

- **Normale** : pH, température, extrait sec, teneur en sel (variabilité naturelle)
- **t de Student** : Comparaison de moyennes sur petits échantillons (ex. avant / après modification de procédé)
- **χ^2 (khi-deux)** : Analyse de la variabilité d'un procédé
- **F (Fisher)** : Comparaison de variabilités, Analyses de type ANOVA
- **Exponentielle / Gamma** : Durées de fermentation, de fonctionnement, temps entre incidents
- **Uniforme** : Hypothèse de variabilité sans préférence particulière (rare mais utile en modélisation)
- **Log-normale** : Données positives et asymétriques (ex. concentrations, rendements)

Exemple :

- Distribution du pH en fin de fermentation
- Comparer le pH moyen avant/Après changement de ferments
- Vérifier si la dispersion du pH reste conforme au cahier de charges
- Comparer la variabilité du rendement matière entre plusieurs lignes de production.

Loi Poisson (comptage d'évènements)


Idée : compter des événements dans un intervalle (lot/heure) avec un taux moyen λ .

Repère : en Poisson, moyenne = variance = λ (diagnostic rapide).

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad (\text{Prob d'observer } k \text{ non-conforme sur } n \text{ essais})$$

Exemple : défauts d'emballage par lot ; alerte si le compte devient anormalement élevé.

À vérifier : événements indépendants, taux globalement constant.



Les événements rares (beaucoup de défauts) ont une probabilité très faible.


Loi Normale (courbe en cloche)

Idée : la plupart des valeurs sont autour de la moyenne, peu sont très éloignées.

Quand : mesures symétriques sans grosses valeurs aberrantes (ex. % Extrait sec stable).

Règle repère : environ 68 % des valeurs à ± 1 * écart-type, 95 % à ± 2 * écart-type.

Exemple fromagerie : % Extrait sec d'un produit en régime stable.



La majorité des observations se situe à proximité de la moyenne, et la probabilité décroît rapidement quand on s'en éloigne.

Loi t de Student (normale “plus large”)

Idée : Comme une loi Normale, mais avec des queues plus épaisses
→ davantage de prudence quand n est petit.

Quand :

- Pour estimer ou tester une moyenne à partir d'un petit échantillon ($\approx < 30$).
- Quand l'écart-type “vrai” de la population est inconnu (cas réel en pratique).


Pourquoi cette loi ?

- Elle compense l'incertitude supplémentaire liée au petit échantillon.
- Plus n augmente, plus la loi t se rapproche de la Normale.

Lien tests / loi t

- Les tests « t » utilisent la loi t de Student avec $df = n - 1$ (degrés de liberté).
- C'est la loi de référence pour les tests de moyenne en petits échantillons.

La loi de Student est proche de la loi normale, mais avec des queues plus épaisses lorsque l'échantillon est petit. Plus le nombre de degrés de liberté est grand, plus l'approximation par la loi normale est pertinente.




Loi χ^2 (Chi-deux) — pour la variabilité

Idée : plus la dispersion observée est grande, plus la statistique “part à droite”.

Quand : tester une variance ou construire un IC de variance (variable $\approx$ normale).

Exemple : la variance d'Extrait sec a-t-elle augmenté après réglage de pressage ?

Lien tests/IC : IC et test de σ^2



La loi du χ^2 est une distribution positive et asymétrique qui se rapproche d'une forme plus symétrique quand les degrés de liberté augmentent.

Loi F (Fisher) — comparer des variances / ANOVA


Idée : rapport “variabilité entre groupes / dans les groupes”.

Quand :

- comparer deux variances ($F = s_1^2 / s_2^2$),
- ANOVA : tester si les moyennes de ≥ 3 groupes sont différentes.

Exemple : % Extrait sec selon Produit A/B/C → ANOVA (test F).

À vérifier : variances pas trop différentes (Levene), indépendance des observations.



La loi de Fisher est une loi positive et asymétrique, dont la forme dépend des degrés de liberté et qui se concentre autour de 1 lorsque ceux-ci augmentent.

Quel test avec quelle loi ?

Différentes situations :

- Moyenne (n petit, σ inconnue) $\rightarrow$ t de Student (test t, IC t).
- Moyenne (n grand ou normalité OK) $\rightarrow$ Normale (Z-test, IC).
- Variance $\rightarrow \chi^2$ (IC/test de σ^2).
- Comparer ≥ 3 moyennes $\rightarrow$ F (ANOVA).
- Proportion $\rightarrow$ Binomiale (test/IC de p).
- Comptage d'événements $\rightarrow$ Poisson (tests sur λ , comparaisons de taux).

Avant d'appliquer un test :

- Bien typer la variable : discrète (compte) / continue (mesure) / proportion.
- Indépendance des observations (attention aux lots/recettes/cuves). Stabilité du procédé sur la fenêtre analysée.
- Graphiques avant test : histogramme + densité, QQ-plot (Normale/t), Boxplot (Binomiale/Poisson).
- Robuste si doute : médiane/IQR, bootstrap d'IC, tests non paramétriques.

Intervalles de confiance : mesurer la confiance dans nos résultats



Plan du chapitre :

- Passer d'un chiffre (la moyenne) à une fourchette (IC)
- Comprendre pourquoi on a besoin de lois de référence (Normal / t / χ^2)
- Préparer la suite : tests (Student/ANOVA) et adéquation (résidus / normalité)

Intervalle de confiance IC

Pourquoi un intervalle de confiance IC?

- On ne mesure jamais "la réalité complète" : on observe un échantillon.
- Si on recommence la mesure (autres lots/jours/conditions), la moyenne change.

Un intervalle de confiance donne une fourchette crédible pour une valeur inconnue (moyenne, proportion...), en tenant compte de la variabilité des données.

En pratique, il permet de répondre à la question :

« Quelle est la valeur probable et avec quelle incertitude ? »

Ce que l'intervalle de confiance prend en compte

- La variabilité des mesures (les données sont plus ou moins dispersées)
- Le nombre de mesures (plus on mesure, plus la fourchette est précise)
- Le niveau de sécurité choisi (souvent 95 % en entreprise)

Comment l'utiliser ?

- Comparer deux procédés / recettes
- Vérifier si un objectif ou une spécification est atteint
- Quantifier l'incertitude avant une décision

L'intervalle de confiance indique la marge d'erreur autour d'une estimation

Degré de liberté

Définition : C'est le nombre de mouvements indépendants possibles pour un système ou un objet. Autrement dit, c'est le nombre de façons dont il peut bouger sans être contraint.

Exemple : Lorsqu'on effectue un test statistique (par exemple, vérifier si le pH moyen des fromages respecte une norme), le degré de liberté correspond au nombre de valeurs indépendantes qui peuvent varier dans le calcul, après avoir pris en compte.

Cas concret :

- On prélève $n = 10$ échantillons de fromage pour mesurer le pH.
- On calcule la moyenne des 10 valeurs.
- Une fois la moyenne fixée, seulement 9 valeurs peuvent varier librement (la 10^e est contrainte par la moyenne).

👉 Degré de liberté = $n - 1 = 10 - 1 = 9$.

Valeur critique : à quoi ca sert ?

La **valeur critique** est un seuil de décision. Elle permet de savoir si une différence observée est compatible avec le hasard ou suffisamment grande pour être prise en compte.

À quoi sert-elle ?

- Fixer une règle claire avant l'analyse
- Éviter les décisions arbitraires
- Traduire un résultat statistique en oui / non-métier

De quoi dépend la valeur critique ?

- Du nombre de mesures → peu de données = plus prudent
 - Du risque accepté (ex. 5 %) → risque d'annoncer une différence alors qu'il n'y en a pas
- 👉 Plus on a de données, plus le seuil est précis.

Lien avec les tests statistiques

- Les tests (Student, χ^2 , ANOVA...) comparent une valeur calculée à une valeur critique
- Si on dépasse le seuil → différence significative

Structure d'un IC de moyenne

IC de la moyenne : la structure (avant la loi t)

Un intervalle de confiance pour la moyenne s'écrit toujours

$$IC = \bar{x} \pm (\text{valeur critique}) \times (\text{erreur standard})$$

Erreur standard (SE) :

$$SE = \frac{s}{\sqrt{n}}$$

s = écart-type de l'échantillon

n = taille d'échantillon

Valeur critique : dépend du **niveau de confiance** (ex. 95%) et de la **loi de référence** (normal ou t)

Lecture métier :

- **s** grand → IC plus large
- **n** grand → IC plus serré
- **95%** → compromis "courant" entre prudence et précision

Niveau de confiance & valeur critique (quantile)

Niveau de confiance (ex. 95%) — que signifie-t-il ?

- On construit un intervalle par une méthode qui, si l'on répétait l'expérience, contiendrait la vraie valeur dans 95% des cas.
- Ce n'est pas "95% de chances que la vraie moyenne soit dans cet intervalle" (interprétation bayésienne).

Valeur critique — d'où vient-elle ?

- La valeur critique est un quantile d'une loi de référence (Normale ou t).
- À 95% (bilatéral) : on coupe 2,5% dans chaque queue → quantile 0,975.
- Exemple : $z_{0.975} = 1,96$, (normale), ou $t_{0.975, n-1}$ (Student).

Interpréter un IC (ce que ça dit / ne dit pas)

Intervalles de confiance — bien interpréter (et éviter les pièges)

Ce que dit un IC à 95% (fréquentiste) :

- Si on répétait l'échantillonnage, **95% des IC construits** contiendraient la vraie moyenne μ .
- Un IC large = **incertitude élevée** (variabilité forte et/ou n faible).

Ce qu'un IC ne dit pas :

- "Il y a 95% de chances que μ soit dans cet intervalle" (ce n'est pas une probabilité sur μ).
- "95% des données sont dans l'intervalle" (l'IC concerne la **moyenne**, pas les observations).

Lecture opérationnelle :

- IC entièrement au-dessus d'un seuil → décision plus solide
- IC recouvre un seuil → prudence (besoin de données / segmentation / modèle)

Exemple 1

Exemple pratique : Un chercheur mesure la taille moyenne d'une population d'étudiants. L'échantillon de 100 étudiants donne une moyenne $\bar{X}$ de 170 cm avec un écart-type (σ) de 10 cm.

Calcul de l'IC à 95 % :

1. Erreur standard (SE) : $SE = \sigma / \sqrt{n} = 10 / \sqrt{100} = 1$ cm
2. Valeur critique (Z) : Pour 95 %, $Z = 1,96$.
3. Intervalle de confiance :

$$IC = [\bar{X} - Z \times (SE), \bar{X} + Z \times (SE)]$$

$$IC = [170 - 1,96 \times 1, 170 + 1,96 \times 1] = [168,04 \text{ cm}, 171,96 \text{ cm}]$$

Interprétation : Avec un niveau de confiance de 95 %, la taille moyenne de la population est très probablement comprise entre 168,04 cm et 171,96 cm.

Exemple 2

Exemple : % d'humidité d'un fromage

Contexte :

- 100 fromages mesurés
- % H₂O moyen mesuré : 52,0 %
- Variabilité observée dans les mesures

Résultat Intervalle de confiance à 95 % : [51,0 % ; 53,0 %]

Interprétation métier : avec un niveau de confiance de 95 %, le % d'humidité réel est très probablement compris entre 51 % et 53 %.

Décision possible

- Conforme à la cible → pas d'action
- Intervalle trop large → plus de mesures
- Intervalle hors spécification → ajustement du procédé

Pourquoi la loi t (σ inconnu) + degrés de liberté + valeur critique

Pourquoi la loi t ? (σ inconnu en pratique)

- En situation réelle, l'écart-type "vrai" σ de la population est **inconnu**.
- On le remplace par l'écart-type de l'échantillon s → cela ajoute de l'incertitude.

Conséquence : on utilise la **loi t de Student** pour un IC de moyenne.

Degrés de liberté (ddl) :

$$ddl = n - 1$$

→ parce qu'une fois la moyenne fixée, seules $n - 1$ valeurs peuvent "varier librement"

Valeur critique (quantile) à 95% :

$$t_{\{0,975,ddl\}}$$

- plus n est petit → t est plus grand → IC plus large (prudence) :
- quand n augmente → t se rapproche de 1,96 (normale)

Visualisations “pré-IC” : vérifier que l’IC est crédible

Avant d'utiliser un IC : visualiser pour vérifier les hypothèses

Pourquoi ?

Un **IC** de moyenne basé sur la loi t est robuste en pratique, mais il est plus fiable si :

- les données ne sont pas dominées par quelques valeurs extrêmes,
- le comportement est raisonnablement “stable” sur la fenêtre analysée.

Visualisations clés (simples et rapides) :

- Histogramme : forme globale (symétrie, asymétrie, multimodalité)
- Boxplot : dispersion + outliers + comparaison par groupes (périodes/sites/modes)
- Nuage de points (si une variable explicative existe) : repérer structure/rupture

Signaux d'alerte (à commenter, pas à “corriger” automatiquement) :

- outliers nombreux ou très extrêmes
- forte asymétrie (queue longue)
- multimodalité (mélange de régimes)
- rupture temporelle / changement de conditions

Que faire si alerte ? (réflexes utiles)

- résumer aussi avec médiane/IQR en complément
- segmenter (période/site/mode) plutôt que moyenner “tout ensemble”
- documenter et investiguer la cause (mesure vs événement réel)

Application : IC95% de la moyenne d'Indice_Qualite (méthode)

Application — IC 95% de la moyenne (Indice_Qualite)

Objectif : encadrer le “vrai niveau” moyen d'Indice_Qualite.

Étapes (méthode) :

1. Calculer $\bar{x}$, s , n sur l'échantillon
2. Calculer l'erreur standard :

$$SE = \frac{s}{\sqrt{n}}$$

3. Choisir la valeur critique :

$$t_{0,975,n-1}$$

4. Construire l'IC :

$$\bar{x} \pm t_{0,975,n-1} \frac{s}{\sqrt{n}}$$

Interprétation :

- IC plus serré → estimation plus précise
- IC qui recouvre une cible/seuil → conclusion prudente (à confirmer)

DEMO Excel : calcul IC95% (pratique)

DEMO Excel — Calculer un IC 95% de moyenne

Données : une série de valeurs d'Indice_Qualite (plage Excel)

➤ **Calculs de base**

- $\bar{x}$: =MOYENNE(plage)
- s (échantillon) : =ECARTYPE.STANDARD(plage)
- n : =NB(plage)
- SE : =ECARTYPE.STANDARD(plage)/RACINE(NB(plage))

➤ **Valeur critique (95%, bilatéral)**

- =T.INV.2T(0,05; NB(plage)-1) (ou équivalent selon version Excel)

➤ **Intervalle**

- Borne basse : =MOYENNE(plage) - t_crit*SE
- Borne haute : =MOYENNE(plage) + t_crit*SE

Même calcul pour “global” et “par période” : seule la plage de données change.

IC95% de la moyenne par période (Comparer correctement)

IC95% par période — comparer “niveau” + “incertitude”

Objectif : estimer et comparer la moyenne “réelle” d’**Indice_Qualite** pour chaque période (P1 à P4) avec une incertitude explicite.

Méthode (pour chaque période k) :

$$IC_k = \overline{x}_k \pm t_{0,975,n_k-1} \frac{s_k}{\sqrt{n_k}}$$

- $\overline{x}_k$: moyenne d’Indice_Qualite sur la période k
- s_k : écart-type (échantillon) sur la période k
- n_k : taille d’échantillon sur la période k

Comment lire / comparer :

- **Largeur de l’IC** → précision (dépend de s_k et n_k)
- **IC qui se chevauchent** → différence possible, mais pas “prouvée” (on validera plus tard avec Student/ANOVA)
- **IC non chevauchants** → forte indication d’une différence de niveau (à confirmer par test)

Livrable recommandé :

- Tableau récapitulatif : $\overline{x}_k$, s_k , n_k , borne basse, borne haute
- Un graphique de comparaison : barres/points avec barres d’erreur (IC)

Comparer des moyennes sans IC, c’est comparer des chiffres sans notion de risque

Pont entre IC et tests (Student / ANOVA)

IC $\leftrightarrow$ Tests

même logique MAIS question différente

IC (intervalle de confiance)

- Question : “Quelle est la fourchette plausible de la vraie moyenne ?”
- Résultat : une estimation **avec incertitude** (marge d'erreur).

Test d'hypothèse (Student / ANOVA)

- Question : “La différence observée est-elle compatible avec le hasard ?”
- Résultat : une **décision** sous risque maîtrisé (p-value / seuil α).

Lien direct (à retenir)


- Un test est “la même mécanique” qu'un IC :
 - valeur critique / quantile
 - erreur standard
 - règle de décision

À 95% :

- IC $\leftrightarrow$ **test au seuil** $\alpha=5\%$ (cohérence de niveau de risque)

Formules sur Excel

Loi	Valeur critique	IC	Paramètres	Excel
Normale	$z_{1-\alpha}$	$\bar{x} \pm z \frac{\sigma}{\sqrt{n}}$	μ, σ	NORM.S.INV
Student	$t_{1-\alpha, v}$	$\bar{x} \pm t \frac{s}{\sqrt{n}}$	$v = n-1$	T.INV
Khi-2	$\chi^2_{1-\alpha, v}$	IC variance	$v = n-1$	CHISQ.INV.RT
Fisher	$F_{1-\alpha; v1, v2}$	ANOVA	$v1, v2$	F.INV.RT
Binomiale	—	IC proportion	n, p	BINOM.DIST
Poisson	—	IC λ	λ	POISSON.DIST



**Avant de
commencer
cette
nouvelle
journée**



Votre résumé de la veille ?

Les objectifs de la journée :

- Régression linéaire
 - Revoir les tests statistiques les plus importantes
 - Formuler des hypothèses statistiques à tester
 - Mise en pratique avec le jeu des données.
- 

Régression Linéaire



- comprendre quand et pourquoi utiliser une régression,
- interpréter correctement ses résultats,
- relier métriques (RMSE, MAE, R^2), tests statistiques et résidus,
- appliquer ces concepts aux comparaisons modèle ↔ mesure (cas métier réel).

Transition : de “décrire” à “expliquer/prévoir”

Après les IC : modéliser pour expliquer et prévoir

Jusqu’ici :

- **on décrit** (niveau, dispersion, forme)
- on **quantifie** l’incertitude (IC)

Maintenant :

- on cherche à relier une variable à une autre : *“quand X change, Y change-t-il ?”*
- on veut un modèle simple pour expliquer (comprendre) et parfois prévoir

Exemples de questions typiques :

- Est-ce qu’un indicateur (X) explique une variation d’Indice_Qualite (Y) ?
- Peut-on prédire Y à partir de X, avec un modèle simple et vérifiable ?

Interpolation vs Régression (bruit vs modèle)

Interpolation vs Régression : ne pas confondre

Interpolation

- Objectif : **passer exactement** par les points observés
- Utile quand les mesures sont quasi “sans bruit” ou en calibration contrôlée

Régression

- Objectif : modéliser une relation **malgré le bruit**
- On cherche une tendance “moyenne” (signal) et on accepte des écarts (résidus)

Message pratique

- Si les données sont bruitées (souvent en industrie) → **régression**
- L'interpolation peut sur-ajuster (sur-apprentissage) et donner un modèle “trop optimiste”

Interpolation = exactitude sur les points ; régression = robustesse face au bruit.

Régression linéaire : objectif, sortie, lecture

Régression linéaire (simple) — expliquer / prévoir

Modèle :

$$Y = a + b X + \varepsilon$$

- **Y** : variable à expliquer (ex. Indice_Qualite)
- **X** : variable explicative (ex. Vibration_mm_s, Charge_kNm, etc.)
- **b** : effet moyen de X sur Y (pente)
- **ε** : bruit / facteurs non modélisés (résidus)

Ce qu'on regarde (minimum utile)

- **Signe de b** : relation positive / négative
- **R²** : part de variabilité expliquée (attention : pas une preuve de causalité)
- **Résidus** : le modèle "rate" où, et pourquoi ?

Un bon modèle n'est pas celui qui colle le mieux, mais celui qui reste cohérent et vérifiable (résidus).

Comment estime-t-on les paramètres d'un modèle de régression ?

Objectif : À partir des données observées (X_i, Y_i) , déterminer les valeurs de **a** et **b** qui rendent le modèle :

$$Y = \mathbf{a} + \mathbf{b} * X + \varepsilon$$

le plus cohérent possible avec la réalité.

Principe : Quelle que soit la méthode, l'idée est toujours la même : Choisir **a** et **b** pour rendre les valeurs prédites $\hat{Y}$ aussi proches que possible des valeurs observées Y . La différence $e_i = Y_i - \hat{Y}_i$ correspond aux résidus.

Méthode la plus courante : moindres carrés ordinaires (OLS)

On choisit **a** et **b** pour minimiser la somme des carrés des résidus :

$$\min_{\mathbf{a}, \mathbf{b}} \sum_{t=1}^T \varepsilon_t^2 = \min_{\mathbf{a}, \mathbf{b}} \sum_{t=1}^T (Y_t - \mathbf{a} - \mathbf{b} * X_t)^2$$

Adéquation à un modèle : check-list résidus (indispensable)

Adéquation du modèle : vérifier avec les résidus

Résidu :

$$e_i = y_i - \hat{y}_i$$

Ce que le modèle n'explique pas.

Check-list simple (à faire systématiquement)

- **Résidus centrés** autour de 0 (pas de biais global)
- **Pas de structure** visible (pas de tendance selon X ou selon le temps)
- **Dispersion** à peu près constante (pas d'hétéroscédasticité évidente)
- **Outliers** : rares et explicables (événements, mesure, changement de régime)

Si la check-list échoue

- segmenter (site/période/mode)
- transformer la variable (log, etc.)
- passer à un modèle plus adapté

Estimation du modèle vs évaluation de l'erreur

Question	OLS	RMSE	MAE
Sert à trouver les coefficients ?	Oui (méthode préférable mathématiquement)	Non	Non
Sert à juger la qualité du modèle ?	Non	Oui	Oui
Minimise des carrés ?	Oui	Oui (indirectement)	Non
Sensibilité aux grandes erreurs (outliers)	Forte	Forte	Faible
Utilisé dans les tests (Student, ANOVA, IC)	Oui	Non	Non
Unité de l'indicateur	$(\text{Unité de } Y)^2$ → pas de sens	Même unité que Y	Même unité que Y
Rôle principal en pratique	Estimation du modèle	Évaluation (pénalise extrêmes)	Évaluation (erreur typique)

DEMO : Régression linéaire (Excel / Colab)

DEMO — Régression linéaire : $\text{Indice_Qualite} \sim \text{Vibration_mm_s}$

Objectif : quantifier une relation “simple” entre une variable explicative X et une variable cible Y.

Modèle :

$$\text{Indice} - \text{Qualite} = a + b \times \text{Vibration} + \varepsilon$$

Étapes (pratiques)

- **Tracer un nuage de points** (scatter) :

$$X = \text{Vibration_mm/s} \quad Y = \text{Indice_Qualite}$$

- **Ajuster une droite** (régression linéaire)
- **Lire et commenter** :
 - Signe de b: relation positive / négative
 - Amplitude de b : effet moyen (variation de Y pour +1 unité de X)
 - R^2 : part de variabilité expliquée (indicateur d'utilité, pas de causalité)
- **Règle de restitution**
 - 1 visuel (scatter + droite)
 - 1 chiffre (pente b ou R^2)
 - 1 message (hypothèse + prochaine étape)

DEMO : Vérification d'adéquation via les résidus

DEMO — Adéquation : lire les résidus (diagnostic rapide)

Résidu

$$e_i = y_i - \hat{y}_i$$

Graphiques à produire (minimum)

- Résidus vs valeurs prédites : e_i en fonction de $\hat{y}$
- Histogramme des résidus

Ce qu'on veut voir

- Résidus centrés autour de 0 (pas de biais global)
- Pas de structure visible (pas de courbe, pas de tendance)
- Dispersion à peu près **constante** (pas d'effet "entonnoir")
- Outliers rares et explicables (événements / mesure / changement de régime)

Si on voit une structure

Le modèle est **insuffisant** : segmenter (période/site/mode), transformer, ou enrichir le modèle

Transition vers Chapitre 4 (tests d'adéquation)


Transition — De “vérifier avec les résidus” à “tester l'adéquation”

Dans ce chapitre, on a appris à :

- quantifier l'incertitude sur une moyenne (IC)
- construire un modèle simple (régression)
- vérifier l'adéquation par une lecture visuelle (résidus)

Question naturelle :

- Peut-on objectiver cette adéquation avec un test statistique ?
- Les données (ou les résidus) sont-ils compatibles avec un modèle donné ?



Les tests statistiques : décider avec un risque maîtrisé



Plan du chapitre :

- L'intérêt des tests statistiques dans l'analyse de données
 - Comprendre la logique des tests statistiques
 - Hypothèse nulle vs hypothèse alternative
 - Décision statistique et interprétation des résultats
 - Exemples de tests statistiques usuels (Test de Student Test du χ^2 ANOVA)
- 

Concepts clés & lecture de résultats

Définition : Un test statistique évalue H_0 (hypothèse nulle) contre H_1 (alternative) à l'aide d'une statistique de test et d'une p-value. Ça permet de transformer une observation ("ça a l'air différent / anormal") en décision traçable, avec un risque explicite.

Cadre commun (quel que soit le test) H_0 / H_1 :

- **Hypothèse nulle H_0 :** pas de différence/effet. Ex. "A et B ont la même humidité moyenne."
- **Hypothèse alternative H_1 :** différence/effet présent ($A \neq B$).

Deux paramètres clés :

- **Seuil α :** risque de **fausse alarme** (ex. 5%)
- **p-value :** probabilité d'un résultat aussi extrême si H_0 est vraie.

Seuil usuel : $\alpha = 0,05 \Rightarrow p < \alpha \rightarrow$ rejeter H_0 SINON données compatibles avec H_0

Au-delà de la p-value :

- IC95 % de la différence (amplitude plausible).
- Taille d'effet (Cohen's d, η^2) = pertinence pratique.
- Puissance (probabilité de détecter un effet utile).

Pourquoi une méthodologie pour choisir un test statistique ?

Objectif : éviter les décisions « au doigt mouillé », réduire les fausses alertes / non-détections, et garantir la reproductibilité.

Notre démarche en 6 étapes :

1. Poser la question métier & H_0/H_1
2. Identifier données & design
3. Vérifier les conditions minimales
4. Choisir le test adapté
5. Fixer le plan d'analyse (α , tailles d'effet, IC, post-hoc)
6. Rapporter & décider (statistique et impact atelier)

Message-clé : la bonne décision statistique commence avant le test

Etape 1 : formuler la question & l'hypothèse

But : : transformer une intuition en question testable, claire et mesurable.

Boîte à questions :

- **Niveau** : Le changement A vs B modifie-t-il la valeur moyenne d'un indicateur ?
- **Variabilité (dispersion)** : La dispersion a-t-elle augmenté/diminué par action ?
- **Proportion** : Le taux de défauts d'emballage est-il différent entre deux fournisseurs ?
- **Distribution (adéquation)** : La forme des données est-elle compatible avec un modèle?
- **Association** : Deux variables évoluent-elle ensemble (relation linéaire)?

Écrire H_0/H_1 :

- **H_0 pas d'effet** / pas de différence / pas d'association
- **H_1 : effet** / différence / association présente

Une bonne analyse commence par une question bien posée

Etape 2 : Identifier la nature des données & le design

But : identifier la nature des données pour choisir le bon test.

Trois questions flash :

1. **Type de variable :** quantitative (poids, % H₂O, pH) ou qualitative (conforme / type de défaut) ?
2. **Comparaison :** 2 groupes ou ≥ 3 ? Indépendants (A vs B) ou appariés (avant / après) ?
3. **Objectif :** comparer niveaux, variances, proportions, distributions, ou relation entre 2 quantitatifs ?

Exemples

- Moyennes (2 groupes) → **Student** (indépendants ou appariés)
- Moyennes (≥ 3 groupes) → **ANOVA**
- Catégories / proportions → **χ^2**
- Distribution / normalité → **KS, D'Agostino**
- Relation X-Y → **régression** (et Pearson en exploration)

Type + design + objectif = test

Etape 3 : Vérifier les conditions minimales

Échantillonnage & mesures

- **Représentativité** : couvrir les conditions réelles (périodes, sites, contextes)
- **Traçabilité** : savoir “d’où viennent” les données (site, mode, version, campagne)
- **Qualité de mesure** : capteurs/calculs cohérents (unité, calibration, protocole stable)

Données

- **Taille d’échantillon** : assez de points pour “voir” la variabilité
- **Valeurs extrêmes** : identifier, documenter, traiter avec prudence
- **Premiers visuels** : histogramme/boxplot/scatter → repérer dérive, mélange de régimes

Graphiques + qualité de mesure : le test n’est fiable que si la donnée l’est.

Etape 4 : Choisir le test adapté

Comparer des moyennes (variable quantitative)

- 2 groupes indépendants → **Student**
- 2 mesures appariées (avant/après) → **Student apparié**
- ≥ 3 groupes → **ANOVA** (puis analyses ciblées si besoin)

Comparer des catégories / proportions

- Tableau de contingence → χ^2 (indépendance)

Vérifier une distribution / adéquation

- Normalité → **D'Agostino**
- Adéquation à un modèle (ou comparaison distributions) → **KS**

Relation entre 2 quantitatives

- Exploration : **Pearson**
- Modélisation : **régression linéaire** + diagnostic (résidus)

On choisit le test selon la question – pas selon l'outil disponible

Etape 5 : Plan d'analyse : décider avant de calculer

1. Fixer la règle de décision :

- Choisir le seuil de risque (souvent $\alpha = 5\%$)
- Décider si comparaison bilatérale ou dans un seul sens (selon question métier).

2. Mesurer l'écart utile

- Exprimer l'écart en termes métiers : $\Delta\%$ H₂O, Δ kg, Δ en points %
- Ajouter un intervalle de confiance

3.. Vérifier que les données suffisent

- Avec peu de mesures $\rightarrow$ risque de conclure trop vite "rien à signaler"

4. Prévoir un visuel clair Boîte à moustaches / barres + IC / courbe dans le temps

- Boîte à moustaches / barres + IC / courbe dans le temps

On fixe les règles avant : on « choisit » après coup.

Etape 6 : Rapporter & décider



Comment formuler un résultat statistique utile ?

Toujours structurer :

- **Fait** : différence/association observée (avec unités)
- **Incertitude** : p-value et/ou IC95% (niveau de confiance explicite)
- **Conclusion opérationnelle** : décision + risque + prochaine action
- **Visuel simple** : le graphe qui soutient la conclusion

Toujours indiquer

- Différence mesurée (écart concret)
- Niveau de confiance (incertitude)
- Conclusion opérationnelle Illustration graphique simple



Revenons à l'étape 3 pour parler des hypothèses

Échantillons Appariés vs Échantillons Indépendants

Caractéristique	Échantillons Appariés	Échantillons Indépendants
Type de données	Les données sont liées entre elles (même sujet mesuré à différents moments ou sous différentes conditions)	Les données sont indépendantes (généralement des groupes différents)
Exemple	Avant et après une campagne marketing, ou comparaison de deux produits pour les mêmes clients	Comparaison de l'efficacité de deux campagnes marketing sur des groupes distincts de consommateurs
Méthode de collecte	Données collectées à plusieurs moments pour les mêmes individus	Données collectées auprès de groupes différents de manière indépendante
Tests utilisés	Test t pour échantillons appariés, test de Wilcoxon (si non paramétrique)	Test t pour échantillons indépendants, ANOVA (pour plus de deux groupes)
Objectif	Comparer les résultats d'une même entité avant et après une intervention	Comparer les résultats entre deux groupes indépendants
Formule test-student	$t = \frac{(\bar{X}_2 - \bar{X}_1)}{s_d / \sqrt{n}}$	$t = \frac{(\bar{X}_2 - \bar{X}_1)}{\sqrt{(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2})}}$

Test t pour un échantillon



Y a-t-il une différence entre un groupe et la population ?

Test t pour échantillons indépendants



Y a-t-il une différence entre deux groupes ?

Test t pour échantillons appariés



Y a-t-il une différence au sein d'un groupe entre deux moments dans le temps ?




Normalité des données

L'hypothèse de normalité stipule que les données doivent suivre une distribution normale, particulièrement importante pour les tests de Student. Le test de Shapiro-Wilk pour vérifier la normalité des données.

Points à aborder :

- Si les données suivent une distribution normale, on peut utiliser les tests paramétriques (comme le test de Student).
- Si la p-value du test de Shapiro-Wilk est inférieure à 0,05, les données ne sont pas normalement distribuées et un test non paramétrique devrait être envisagé.

Exemple : Imaginons une analyse des dépenses mensuelles de consommateurs après une campagne de publicité. Si vous testez la normalité des dépenses pour vérifier l'impact de la publicité et que la p-value est inférieure à 0,05, cela suggère que les données ne suivent pas une distribution normale, et vous pourriez envisager des tests non paramétriques comme le test de Mann-Whitney.



Tests of Normality ^a						
	Kolmogorov-Smirnov ^b			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
Age	.178	10	.200 ^c	.944	10	.599

a. Lilliefors Significance Correction

^b. This is a lower bound of the true significance.

On accepte H0
soit la variable
l'Age est normalement
distribuée

La statistique W
de Shapiro-Wilk

Degré de Liberté

Indépendance & Dépendance des échantillons

Contenu :

- **Test pour échantillons indépendants** : Les observations dans les deux groupes doivent être indépendantes.
- **Test pour échantillons appariés** : Les observations sont liées, chaque observation dans le groupe 1 est associée à une observation dans le groupe 2 (avant-après, etc.).

Points à aborder :

- Pour le test **indépendant**, il ne doit y avoir aucune relation entre les échantillons. Par exemple, les comportements d'achat des clients sur deux plateformes distinctes (A vs B) sont indépendants.
- Pour le test **apparié**, chaque participant ou unité dans le premier échantillon doit être lié à un équivalent dans le deuxième échantillon.

Exemple :

- Si vous comparez les comportements d'achat entre deux groupes indépendants (consommateurs exposés à deux types de publicités différentes), vous appliquez un test pour échantillons **indépendants**.
- Si vous comparez les **achats avant et après** une promotion pour le même groupe de consommateurs, vous utilisez un test pour échantillons **appariés**.

Homogénéité des variances

Contenu :


- **L'hypothèse d'homogénéité des variances** stipule que les variances des deux groupes comparés doivent être égales pour le test des échantillons indépendants.
- **Test de Levene** : Ce test permet de vérifier l'égalité des variances entre deux ou plusieurs groupes.

Points à aborder :

- Si la **p-value** du test de Levene est inférieure à 0,05, l'hypothèse d'égalité des variances est rejetée. Dans ce cas, on peut appliquer le **test de Welch**, une version modifiée du test t pour les échantillons indépendants.
- Si les variances sont égales, on utilise directement le test de Student standard.

Exemple :

- Imaginons que vous compariez les **dépenses moyennes** de deux groupes de consommateurs, l'un ayant reçu une offre spéciale et l'autre non. Avant d'effectuer le test de Student, vous devez vérifier que les variances des dépenses dans les deux groupes sont similaires. Si la p-value du test de Levene est inférieure à 0,05, vous utiliserez un test de Welch.



Résumé des hypothèses sous-jacentes

Résumé :

- **Normalité** : Les données doivent suivre une distribution normale (vérifiée avec un test de Shapiro-Wilk).
- **Indépendance (ou dépendance)** : Les observations doivent être indépendantes (ou appariées si nécessaire).
- **Homogénéité des variances** : Les variances des groupes doivent être égales (test de Levene).

Points à aborder :

- La validation de ces hypothèses garantit que le test de Student donne des résultats fiables.
- Si ces hypothèses sont violées, des tests non paramétriques ou des ajustements doivent être effectués.

Synthèse hypothèses minimales (tests du cours)

Student / ANOVA (comparaison de moyennes)

- indépendance (ou appariement correct)
- normalité raisonnable des résidus (approchée)
- variances comparables (ou version robuste / Welch si besoin)

Régression linéaire

- relation linéaire “moyenne” pertinente
- résidus : centrés, variance stable, pas de structure

χ^2 (indépendance)

- effectifs attendus suffisants (règle pratique)
- observations indépendantes

D'Agostino / KS (adéquation)

- échantillon représentatif
- interpréter avec les graphes (histogramme/QQ-plot) : test $\neq$ diagnostic unique

Toujours : graphiques + hypothèses + décision. Jamais « test à l'aveugle ».



Les tests statistiques les plus utilisés en pratique

Le test de Student

Le **test de Student** permet de comparer **la moyenne de deux groupes** afin de déterminer si la différence observée est **réelle** ou simplement due **au hasard**. Il est généralement utilisé lorsque :

- les échantillons sont de taille limitée,
- les variabilités des deux groupes sont comparables.

Pourquoi l'utiliser ?

- **Comparer les moyennes de deux groupes** : vérifier si deux groupes présentent des moyennes significativement différentes (performance, délai, taux, mesure physique, etc)
- **Contrôle qualité/conformité** : S'assurer qu'un nouveau procédé, outil ou réglage produit des résultats conformes.
- **Analyse des procédés** : Tester si une modification (paramètre, méthode, organisation) a un effet mesurable.
- **Validation des hypothèses** : vérifier si deux populations peuvent être considérées comme équivalentes.

Hypothèse de base :

- H_0 : Les moyennes des deux groupes sont égales.
- H_1 : Les moyennes des deux groupes ne sont pas égales.

Exemple :

Comparer le **pH moyen** de deux lots de fromages : **Lot A (procédé standard)** et **Lot B (procédé modifié)**.

- Hypothèse H_0 : Les moyennes du pH sont **identiques** entre les deux lots.
- Hypothèse H_1 : Les moyennes du pH **diffèrent** entre les deux lots.

Test t pour échantillons indépendants

Contenu : Utilisé lorsque l'on compare les moyennes de deux groupes distincts (ex : consommateurs ayant vu une publicité vs ceux qui ne l'ont pas vue).

Hypothèses :

- H_0 : Il n'y a pas de différence significative entre les moyennes des deux groupes.
- H_1 : Il existe une différence significative entre les moyennes des deux groupes.

Formule du test t pour échantillons indépendants :

$$t = \frac{(\overline{X}_2 - \overline{X}_1)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Où $\overline{X}_1$, $\overline{X}_2$: Moyennes des deux groupes ; s_1^2 , s_2^2 : Variances des deux groupes ; n_1 , n_2 : tailles des groupes

Règle de décision :

- si $|t| < t_{critique}$ ou $p_{value} > \alpha$ on accepte H_0
- si $|t| > t_{critique}$ ou $p_{value} \leq \alpha$ on rejette H_0

Exemple 1 - Test t sur deux échantillons indépendants

Objectif : Comparer l'humidité moyenne entre deux procédés de fabrication.

Données :

- **Procédé A :** 12 fromages → humidité moyenne = 48%, écart-type = 1,2%.
- **Procédé B :** 10 fromages → humidité moyenne = 49,5%, écart-type = 1,0%.

Hypothèses :

- H_0 : Les deux procédés donnent la même humidité moyenne.
- H_1 : Les humidités moyennes diffèrent.

Application : On calcule la statistique

$$t = \frac{(\bar{X}_2 - \bar{X}_1)}{\sqrt{(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2})}}$$

et on compare à la valeur critique avec les degrés de liberté appropriés.

Test t pour échantillons appariés

Contenu : Utilisé lorsqu'on compare des mesures avant et après pour le même groupe de consommateurs (par exemple, une campagne publicitaire).

➤ **Hypothèses :**

- H_0 : Il n'y a pas de différence significative entre les moyennes avant et après.
- H_1 : Il existe une différence significative entre les moyennes avant et après.

Formule du test t pour échantillons appariés :

$$t_{obs} = \frac{(\overline{X_2} - \overline{X_1})}{s_d / \sqrt{n}}$$

Où

- s_d : Écart-type des différences
- n : Nombre de paires (nb des observations)

Règle de décision :

- si $|t_{obs}| < t_{critique}$ ou $p_{value} > \alpha$ on accepte H_0
- si $|t_{obs}| > t_{critique}$ ou $p_{value} \leq \alpha$ on rejette H_0

Exemple 2 - Test t sur un échantillon (One-sample t-test)

Objectif : Vérifier si le pH moyen d'un lot de fromages est conforme à la norme (par exemple, pH = 5,3).

Données : Échantillon de 15 fromages → pH mesuré : 5,28 en moyenne, écart-type = 0,05.
Norme attendue : 5,3.

Hypothèses :

- **H₀** : Le pH moyen = 5,3 (conforme à la norme).
- **H₁** : Le pH moyen ≠ 5,3 (non conforme).

Application :

- On calcule la statistique t :

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

- et on compare à la valeur critique de la loi de Student avec n-1 degrés de liberté.

L'Analyse de la Variance (ANOVA)

Définition : L'ANOVA est une méthode statistique permettant de tester si les moyennes de plusieurs groupes sont significativement différentes les unes des autres.

Pourquoi l'utiliser ?

- Identifier si des segments de marché se comportent différemment.
- Comparer plusieurs campagnes marketing ou produits.
- Utilisée pour comparer des groupes (ex. : analyse de la satisfaction client par groupe démographique).

Hypothèse de base :

- H_0 : Il n'y a pas de différence significative entre les moyennes des groupes.
- H_1 : Il existe au moins une différence significative entre les moyennes des groupes.

Exemple marketing : Comparer la performance de 3 campagnes publicitaires : A, B et C.

- Hypothèse H_0 : Les moyennes des ventes sont identiques.
- Hypothèse H_1 : Au moins une moyenne est différente.

Hypothèses et critères d'application

Hypothèses de l'ANOVA :

- Les données suivent une distribution normale.
- Les groupes sont indépendants. Homogénéité des variances (test de Levene).

Critères d'application :

- Plus de deux groupes à comparer.
- Mesure quantitative (ex : ventes, scores).

ANOVA à un facteur

Objectif : Comparer les moyennes de plusieurs groupes qui diffèrent selon une seule variable explicative (facteur).

Exemple

- **Situation** : On souhaite comparer le % de sel obtenu après 24 h pour 3 méthodes de salage différentes.
- **Hypothèse** : Les méthodes de salage ont-elles un effet significatif sur le % de sel ?
- **Exemple** : Méthode M1, M2, M3 appliquées sur des lots comparables ; on veut savoir si les moyennes du % de sel diffèrent entre ces trois méthodes.

Hypothèses du test

- $H_0 : \mu_{M1} = \mu_{M2} = \mu_{M3}$ (pas de différence de moyenne entre méthodes).
- H_1 : Au moins une moyenne est différente.

Mode d'emploi (résumé)

- Vérifier indépendance, normalité (par groupe, ex. Shapiro-Wilk), homogénéité des variances (Levene).
- Calculer la statistique

$$F = \frac{\text{variance entre groupes}}{\text{variance intra - groupe}}$$

- Si $p < \alpha$ (ex. 5 %), conclure à une différence de moyennes et réaliser un post-hoc (p. ex. Tukey) pour identifier quels groupes diffèrent.

ANOVA à plusieurs facteurs

Objectif : Analyser l'effet de plusieurs variables explicatives (facteurs) et leurs interactions sur une moyenne.

Exemple :

- Situation : On souhaite analyser comment le % de sel varie en fonction de deux variables simultanées : la méthode de salage (M1, M2, M3) et la température d'affinage (10 °C, 14 °C).
- Hypothèse : L'effet combiné de la méthode et de la température affecte-t-il le % de sel ?
- Exemple : Le % de sel diffère-t-il entre M1, M2, M3 à 10 °C par rapport à 14 °C ? Savoir si l'effet de la méthode change selon la température (interaction) ?

Hypothèses du test

— Effets principaux

- H_0^A : pas de différence entre niveaux de méthode (M1=M2=M3).
- H_0^B : pas de différence entre niveaux de température (10 °C = 14 °C).

— Interaction :

- $H_0^{A \times B}$: pas d'interaction (l'effet de la méthode ne dépend pas de la température).
- $H_1^{A \times B}$: interaction (l'effet de la méthode dépend de la température).

Mode d'emploi (résumé)

- Plan balancé (mêmes effectifs par combinaison méthode × température), réplication par cellule (≥ 2).
- Vérifier indépendance, normalité des résidus, homogénéité des variances.
- Examiner d'abord l'interaction : si significative, on n'interprète pas les effets principaux seuls → on regarde les effets simples (comparaisons de méthodes à chaque température, ou l'inverse) + graphique d'interaction
- Rapporter : F et p pour méthode, température, interaction, taille d'effet

Exemple : ANOVA à un facteur

Contexte métier: Performance des ventes pour 4 produits (A, B, C, D).

Données :

- Produit A : [10, 12, 11, 13, 12]
- Produit B : [15, 17, 16, 14, 16]
- Produit C : [20, 18, 19, 21, 20]
- Produit D : [25, 23, 24, 26, 25]

Ces données représentent les ventes de quatre produits (A, B, C et D) sur une période donnée, avec des observations répétées (5 observations pour chaque produit).

Question : Existe-t-il une différence significative entre les performances ?

Étapes :

- Calculer les moyennes et variances.
- Effectuer le test ANOVA et interpréter F et p.

Test ANOVA à plusieurs facteurs

Données
sur Excel

Énoncé de l'exercice : Une entreprise souhaite analyser l'impact de deux facteurs sur la satisfaction client (mesurée sur une échelle de 1 à 10).

Les facteurs étudiés sont :

- Région : Les clients proviennent de quatre régions différentes (Nord, Sud, Est, Ouest).
- Type de produit : Les clients ont acheté trois types de produits différents (Type A, Type B, Type C).

L'entreprise a collecté les données de satisfaction auprès de 5 clients pour chaque combinaison de Région et Type de produit.

L'objectif est de déterminer :

- 1) Si la région a un effet significatif sur la satisfaction client.
- 2) Si le type de produit a un effet significatif sur la satisfaction client.
- 3) Si l'interaction entre région et type de produit a un effet significatif sur la satisfaction client.

Données proposées : Les données sont organisées par combinaisons de région et type de produit, et chaque cellule contient une note moyenne de satisfaction donnée par les clients.

Test de khi-deux χ^2

Définition : Mesure l'écart entre des effectifs observés et attendus. Deux cadres :

- Ajustement (goodness-of-fit) : une distribution observée est-elle compatible avec une loi théorique ?
- Indépendance / homogénéité dans un tableau de contingence (variables qualitatives).

La statistique suit approximativement une loi χ^2 avec un certain ddl, si les effectifs attendus sont assez grands ($\approx \geq 5/\text{cellule}$, règle pratique).

Quand l'utiliser :

- Indépendance entre fournisseur et défaut d'emballage (conforme/non, type de défaut).
- Ajustement : nombre de défauts/lot suit-il une Poisson (ou autre modèle) ?

Étapes :

1. Formuler **H₀** (indépendance / conformité à la loi) et **H₁** (dépendance / non-conformité).
2. Calculer effectifs attendus; $\chi^2 = \sum (\text{Obs} - \text{Att})^2 / \text{Att}$; déterminer ddl.
3. Lire p-value (χ^2 , ddl).
4. Conclure métier (impact qualité).

Exemple fromagerie :

- **H₀** : le taux de non-conformes n'est pas lié au fournisseur ;
- **H₁** : il est lié. Si $p < 0,05$, cibler le fournisseur ou la cause racine.

Exercice : Test du χ^2 sur la conformité des emballages

Contexte : Une fromagerie souhaite vérifier si la proportion de défauts d'emballage est conforme à la norme interne. La norme stipule que 95 % des emballages doivent être conformes et 5 % peuvent présenter des défauts.

Données observées sur 200 emballages :

- Conformes : 186
- Défauts : 14

Hypothèses :

- H_0 : La distribution observée est conforme à la norme (95 % conformes, 5 % défauts).
- H_1 : La distribution observée n'est pas conforme à la norme.

Solution

Étapes de la solution :

1. Calcul des effectifs attendus : Conformes : $200 \times 0,95 = 190$ Défauts : $200 \times 0,05 = 10$

2. Formule du χ^2 :

$$\chi^2 = \sum_{i=1}^2 \frac{(O_i - E_i)^2}{E_i}$$

où O_i = effectif observé, E_i = effectif attendu.

3. Calcul :

$$\chi^2 = \frac{(186 - 190)^2}{190} + \frac{(14 - 10)^2}{10} = \frac{(-4)^2}{190} + \frac{(4)^2}{10} = \frac{16}{190} + \frac{16}{10} \approx 1,684$$

4. Degrés de liberté :

$$df = k - 1 = 2 - 1 = 1$$

5. Valeur critique ($\alpha = 0,05$) :

$$\chi_{crit}^2 \approx 3,84$$

6. Conclusion :

- $\chi^2 = 1,684 < 3,84 \rightarrow$ on ne rejette pas H_0 .
- La proportion de défauts est conforme à la norme.

Test de D'Agostino (normalité)

Définition : Le test de D'Agostino permet de vérifier si une série de données est compatible avec une distribution normale, en analysant :

- l'asymétrie (skewness),
- l'aplatissement (kurtosis).

Il répond à la question : La distribution observée est-elle compatible avec une loi normale ?

Hypothèses

- H_0 : les données suivent une distribution normale
- H_1 : les données ne suivent pas une distribution normale

Principe (idée clé) : Combine deux informations :

- skewness → symétrie de la distribution
- kurtosis → poids des queues / concentration centrale Produit une p-value globale de normalité

Quand l'utiliser

- Vérifier une hypothèse de modèle (IC, Student, ANOVA, régression)
- Tester la normalité des résidus (cas recommandé)
- Compléter un diagnostic visuel (histogramme, QQ-plot)

D'Agostino teste la normalité, pas la pertinence du modèle

Test de–Smirnov Kolmogorov (KS)

Définition : Le test de Kolmogorov–Smirnov permet de **comparer une distribution de données** à une distribution de référence, ou de comparer deux distributions entre elles.

Il sert à répondre à la question : « Les données observées suivent-elles la même distribution que celle attendue ? »

Deux usages courants :

- **KS à 1 échantillon** : comparer des données à une loi théorique (ex. normale)
- **KS à 2 échantillons** : comparer deux séries de données entre elles

Hypothèses

- H_0 : les distributions sont identiques
- H_1 : les distributions sont différentes

Quand l'utiliser :

- Vérifier la stabilité globale d'un procédé
- Détecter une dérive de comportement
- Tester l'adéquation d'un modèle (ou des résidus)

KS compare des distributions entières, pas de moyennes.

Remplir ce tableau

Type de variable	Comparaison	Test à utiliser
Quantitative	1 échantillon vs valeur	
Quantitative	2 groupes indépendants	
Quantitative	2 mesures appariées	
Quantitative	>2 groupes	
Binaire + Catégorielle	dépendance	
Quantitative + Quantitative	relation	



Je reste
disponible pour
toute question

Atelier 2



Activité

3h heures

Une organisation industrielle instrumentée souhaite **mieux maîtriser la performance et la fiabilité** d'un système (process / maintenance) et comprendre l'évolution de ses indicateurs au cours du temps.

Données mises à disposition (périodes 1 à 4) :

- **Indice_Qualite** (variable cible)
- Vibration_mm_s, Arret_min, Defaults_nb (maintenance/fiabilité)
- Temperature_C, Pression_bar, Charge_kNm (process)
- Variables catégorielles : Periode, Site, Mode_Operatoire
- un sous-ensemble Avant/Après : Vibration_AVANT / Vibration_APRES (mêmes unités)

Objectif maintenant

Utiliser les tests statistiques pour répondre à des questions métier concrètes et proposer des recommandations opérationnelles.

Règle du jeu

- On vous donne une question métier
- Vous choisissez le test
- Vous revenez avec une décision

Par exemple

- Mission 1 — Deux périodes différent-elles réellement ?
- Mission 2 — Une intervention a-t-elle réduit la vibration ?
- Mission 3 — La performance dépend-elle de la période ?
- Mission 4 — Plusieurs facteurs influencent-ils la performance ?
- Mission 5 — La non-conformité dépend-elle du site ?
- Mission 6 — Les données sont-elles compatibles avec une loi normale ?
- Mission 7 — Une distribution a-t-elle changé ?

Mission 1 — Comparer deux groupes indépendants (niveau moyen)

Question métier Le niveau moyen d'Indice_Qualite est-il réellement différent entre deux groupes indépendants ? (ex. période 1 vs période 2, ou Site_A vs Site_B, ou Mode_1 vs Mode_2)

Données à utiliser :

- Variable cible : Indice_Qualite
- Variable de groupe (au choix) : Periode ou Site ou Mode_Operatoire
- Choisir deux groupes (A et B) et justifier le choix.

Travail demandé

- Formuler H_0 / H_1
- Produire un **graphique** de comparaison (recommandé : boxplot + points si possible)
- Choisir une **méthode statistique adaptée** pour décider si la différence observée est compatible avec le hasard
- Conclure : **rejeter / ne pas rejeter H_0** au seuil $\alpha=5\%$

Livrables attendus

- **1 graphique** (comparaison A vs B)
- **1 chiffre** (p-value ou IC de la différence)
- **1 message** (3 lignes max) : fait → incertitude → décision → action



Mission 2 — Avant / Après (mêmes unités mesurées deux fois)

Question métier : Une intervention (maintenance / réglage / calibration) a-t-elle réellement modifié la vibration ?
En particulier : la vibration a-t-elle diminué de façon crédible ?

Données à utiliser :

- Sous-ensemble **Avant_Apres_Vibration**
- Variables : **Vibration_AVANT**, **Vibration_APRES**
- Chaque ligne correspond à la **même unité** mesurée deux fois (avant puis après).

Travail demandé

- Formuler H_0 / H_1 en français simple
 - H_0 : “pas de changement moyen”
 - H_1 : “changement moyen” (ou “diminution” si vous justifiez un test unilatéral)
- Produire un **graphique** de comparaison recommandé : boxplot AVANT vs APRES (+ éventuellement la série des différences)
- Choisir une méthode statistique adaptée au design “mêmes unités mesurées deux fois”
- Conclure : rejeter / ne pas rejeter H_0 au seuil $\alpha=5\%$

Livrables attendus

- **1 graphique** (AVANT vs APRES)
- **1 chiffre** (p-value et/ou IC de la différence moyenne)
- **1 message** (3 lignes max) : fait → incertitude → décision → action

Mission 3 — Comparer plusieurs groupes (≥ 3 niveaux) : effet d'un facteur

Question métier : Le niveau moyen d'**Indice_Qualite** dépend-il d'un facteur à plusieurs niveaux ?
Exemples de facteur : **Période (1 à 4)**, **Site (A/B/C)**, ou **Mode_Operatoire (1/2/3)**.

Données à utiliser

- Variable cible : **Indice_Qualite**
- Choisir un **facteur** parmi : **Période** ou **Site** ou **Mode_Operatoire**
- Utiliser tous les niveaux disponibles (≥ 3 groupes)

Travail demandé

- Formuler **H₀ / H₁** en français simple **H₀** : toutes les moyennes sont égales **H₁** : au moins une moyenne diffère
- Produire un graphique de comparaison multi-groupes : boxplot par groupe (+ points si possible)
- Choisir une méthode statistique adaptée à une comparaison de plus de deux moyennes
- Conclure : rejeter / ne pas rejeter H₀ au seuil $\alpha=5\%$

Livrables attendus

- 1 graphique (boxplot multi-groupes)
- 1 chiffre (p-value du test global)
- 1 message (3 lignes max) : fait → incertitude → décision → action

Mission 4 – plusieurs facteurs : effets combinés (et interaction)

Question métier : La performance (**Indice_Qualite**) dépend-elle de plusieurs facteurs en même temps ? Et surtout : l'effet d'un facteur change-t-il selon l'autre ? (interaction)

Données à utiliser

Variable cible : Indice_Qualite

Facteurs (au choix, recommandation) : Periode (1 à 4) Mode_Operatoire (1 à 3) (Option : remplacer un facteur par Site si vous préférez)

Travail demandé

- **Formuler H_0 / H_1** en français simple : **H_0A** : pas d'effet du facteur A (ex. Periode) **H_0B** : pas d'effet du facteur B (ex. Mode_Operatoire) **$H_0A \times B$** : pas d'interaction (l'effet de A ne dépend pas de B)
- Produire un **visuel** pour préparer l'analyse : boxplots par groupes (ex. Periode) stratifiés par l'autre facteur.
- Choisir une **méthode statistique qui teste** : effet de A, effet de B, et interaction
- Conclure au **seuil $\alpha=5\%$** : quels effets sont crédibles ? y a-t-il une interaction ?

Livrables attendus

- 1 visuel (comparaison multi-groupes / interaction)
- 1 tableau de résultats (p-values des effets A, B, interaction)
- 1 message (3–5 lignes max) : fait → incertitude → décision → action / recommandation

Multi-facteurs : on teste d'abord l'interaction, puis on interprète les effets principaux

Mission 5 – Dépendance entre catégories : le contexte influence-t-il la non-conformité ?

Question métier : Le statut NonConforme dépend-il du contexte ? Par exemple : Site, Periode ou Mode_Operatoire influencent-ils la proportion de non-conformes ?

Données à utiliser

- Variable binaire : NonConforme (0/1)
- Variable de contexte (au choix) : Site ou Periode ou Mode_Operatoire

Travail demandé

- **Formuler H_0 / H_1** en français simple : H_0 : NonConforme est indépendant du contexte H_1 : NonConforme dépend du contexte
- Construire **un tableau de contingence** :
 - lignes = niveaux du contexte (ex. Site_A/Site_B/Site_C)
 - colonnes = NonConforme (0/1)
 - valeurs = effectifs
- **Visualiser les résultats** : barres empilées / % par groupe (taux de non-conformes)
- **Choisir une méthode** de test adaptée à des effectifs (catégories)
- **Conclure au seuil $\alpha=5\%$** : rejeter / ne pas rejeter H_0

Livrables attendus

- 1 tableau (contingence + taux en %)
- 1 chiffre (p-value)
- 1 message (3 lignes max) : fait → incertitude → décision → action

Ici on ne compare pas des moyennes : on teste une dépendance entre catégories (taux/proportions).

Mission 6 (Adéquation / Normalité) — sans dire “D’Agostino”

Question métier

Les données (ou les résidus d’un modèle) sont-ils compatibles avec une distribution “à peu près normale” ? Objectif : savoir si l’on peut raisonnablement utiliser des outils paramétriques (IC/Student/ANOVA) sans fragiliser la conclusion.

Données à utiliser (au choix) Option A : Indice_Qualite (distribution de la variable cible)
Option B (recommandée) : résidus d’une régression simple (Indice_Qualite ~ Vibration_mm_s)

Travail demandé

- Formuler H_0 / H_1
- Produire un visuel de diagnostic : histogramme
- Appliquer un test de normalité adapté
- Conclure au seuil $\alpha=5\%$: rejeter / ne pas rejeter H_0
- Interpréter “métier” : quelles conséquences pour la suite ?

Livrables attendus

- 1 visuel (histogramme ± QQ-plot)
- 1 chiffre (p-value)
- 1 message (3 lignes max) : fait → incertitude → décision → action

Ici normalité testée = décision sur une hypothèse de modèle, pas une fin en soi.

Mission 7 (Adéquation de distribution) — sans dire “KS”

Question métier : Le comportement observé est-il compatible avec une distribution attendue, ou révèle-t-il un écart significatif ? (utile pour valider une hypothèse de modèle, ou comparer stabilité vs dérive)

Données à utiliser (recommandation)

- Arret_min (souvent asymétrique) ou les résidus d'un modèle simple
- Distribution de référence : normale (après standardisation si nécessaire)

Travail demandé

- Formuler H_0 / H_1
- Produire un visuel : histogramme + repérage de la forme (asymétrie/queues)
- Appliquer un test d'adéquation à une distribution de référence
- Conclure au seuil $\alpha=5\%$

Livrables attendus

- 1 visuel (histogramme)
- 1 chiffre (p-value)
- 1 message (3 lignes max) : fait → incertitude → décision → action

Mapping corrigé

Corrigé — Quel test correspond à quelle mission ?

- Mission 1 (2 groupes indépendants, moyenne) → t-test Student (indépendants)
- Mission 2 (avant/après mêmes unités) → t-test Student (apparié)
- Mission 3 (≥ 3 groupes, 1 facteur) → ANOVA 1 facteur
- Mission 4 (≥ 2 facteurs, interaction possible) → ANOVA multi-facteurs
- Mission 5 (catégories / taux, dépendance) → χ^2 d'indépendance
- Mission 6 (normalité) → test de D'Agostino
- Mission 7 (adéquation à une distribution) → Kolmogorov–Smirnov (KS)

Ce qu'il faut retenir de cette formation

1. Avant tout :

- comprendre les données: Identifier le type de variable (quantitative, catégorielle, binaire).
- Nettoyer, structurer, explorer les données avant toute analyse.
- Utiliser histogrammes, boxplots, nuages de points → pour comprendre la distribution, les écarts, les tendances.
- Toujours observer les périodes, les patterns, les outliers.

2. Les tests statistiques : choisir le bon outil

- t-test → comparer 2 groupes (indépendants ou appariés).
- ANOVA → comparer ≥ 3 groupes (ex. Période 1–4).
- Tukey → comparaison post-hoc pour savoir où sont les différences.
- χ^2 → tester des proportions / dépendances entre catégories.
- Corrélation & régression → analyser les relations entre variables.
- Poisson → analyser des comptages (non-conformités / lots). 🧪

3. La logique commune derrière tous les tests

- Toujours commencer par formuler : H_0 : "pas de différence / pas d'effet" H_1 : "il existe une différence / un effet"
- Les tests donnent une p-value : $p < 0,05$ → différence significative $p \geq 0,05$ → données compatibles avec H_0
- La statistique ne démontre pas, elle mesure la probabilité d'observer nos données sous H_0 .



Fin de
formation

Echanges

Merci !

- Formulaire évaluation à recevoir et remplir svp.

— ...

— ...

— ...

— ...

